



# Taller:

# Introducción a las ciencias de datos con Python

24.05.04



# Agenda (2024-05-04)

- 5 min. Presentación
- 35 min. Introducción
- 125 min. Taller
- 10 min. Preguntas
- 5 min. Aprendizajes

5 min. Presentación

# Luis Antonio (FunkyM0nk3y) Galindo Castro

- Ingeniero en computación, UNAM
- Diplomado en Big Data, Ciencias de Datos por el ITESM y Técnicas de buceo Aplicadas a la investigación Subacuática por la UNAM
- Más de 25 años en la industria de tecnología
- Cerca de 20 años participando como ponente en congresos nacionales e internacionales
- Miembro de la Open Source Initiative durante 10 años
- Miembro de la Linux Foundation durante 8 años  
[funkymonster@linux.com](mailto:funkymonster@linux.com)
- Buzo y geek ->



35 min. Introducción

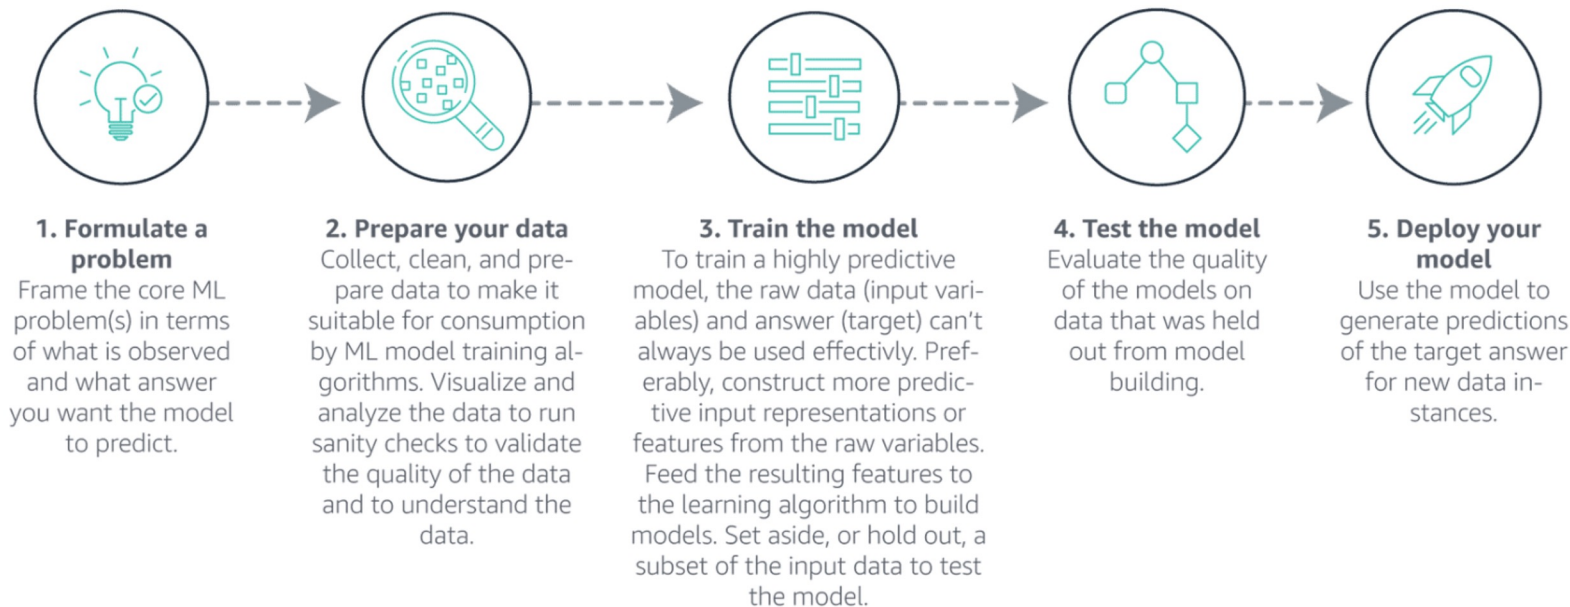
# Calentando motores

Dos opciones en la vida:


- Pastilla roja: DIY, habrá que instalar jupyter y todo lo necesario para el workshop
- Pastilla azul: Utilizar Google Collab y después tomarse la pastilla roja



# Ciclo de vida de los retos con datos



# Fuentes de datos





# ¿De dónde pueden venir los datos?

En la actualidad las fuentes son muy diversas, así como sus formatos



<- Datos en formatos analógicos y formatos no estructurados

Datos provenientes de sensores ->



```
21:20:03.000 -> {alturaConst:2271,temperaturaReferencia:25.04,humedadAmbiente:51.77,temperaturaAmbiente:24.48,co2ppmAmbiente:812,humedadSustrato:318.00,ventilador:0}
21:20:03.000 ->
21:21:03.002 -> {alturaConst:2271,temperaturaReferencia:25.04,humedadAmbiente:51.82,temperaturaAmbiente:24.45,co2ppmAmbiente:815,humedadSustrato:319.00,ventilador:0}
21:21:03.002 ->
21:21:56.455 -> {alturaConst:2271,temperaturaReferencia:24.95,humedadAmbiente:51.87,temperaturaAmbiente:24.45,co2ppmAmbiente:820,humedadSustrato:313.00,ventilador:0}
21:21:56.455 ->
21:22:54.666 -> {alturaConst:2271,temperaturaReferencia:24.95,humedadAmbiente:51.95,temperaturaAmbiente:24.47,co2ppmAmbiente:827,humedadSustrato:310.00,ventilador:0}
21:22:54.666 ->
21:23:58.410 -> {alturaConst:2271,temperaturaReferencia:24.95,humedadAmbiente:52.03,temperaturaAmbiente:24.45,co2ppmAmbiente:834,humedadSustrato:310.00,ventilador:0}
21:23:58.410 ->
21:24:53.006 -> {alturaConst:2271,temperaturaReferencia:24.87,humedadAmbiente:52.11,temperaturaAmbiente:24.50,co2ppmAmbiente:835,humedadSustrato:307.00,ventilador:0}
21:24:53.006 ->
21:25:56.448 -> {alturaConst:2271,temperaturaReferencia:25.04,humedadAmbiente:52.20,temperaturaAmbiente:24.47,co2ppmAmbiente:838,humedadSustrato:320.00,ventilador:0}
21:25:56.448 ->
21:26:52.982 -> {alturaConst:2271,temperaturaReferencia:25.04,humedadAmbiente:52.30,temperaturaAmbiente:24.48,co2ppmAmbiente:839,humedadSustrato:311.00,ventilador:0}
21:26:52.982 ->
21:27:52.990 -> {alturaConst:2271,temperaturaReferencia:24.87,humedadAmbiente:52.34,temperaturaAmbiente:24.50,co2ppmAmbiente:839,humedadSustrato:318.00,ventilador:0}
21:27:52.990 ->
21:28:48.535 -> {alturaConst:2271,temperaturaReferencia:24.95,humedadAmbiente:52.35,temperaturaAmbiente:24.47,co2ppmAmbiente:842,humedadSustrato:312.00,ventilador:0}
21:28:48.569 ->
21:29:52.976 -> {alturaConst:2271,temperaturaReferencia:25.04,humedadAmbiente:52.43,temperaturaAmbiente:24.48,co2ppmAmbiente:843,humedadSustrato:320.00,ventilador:0}
21:29:52.976 ->
21:30:52.979 -> {alturaConst:2271,temperaturaReferencia:25.04,humedadAmbiente:52.46,temperaturaAmbiente:24.48,co2ppmAmbiente:843,humedadSustrato:316.00,ventilador:0}
21:30:52.979 ->
21:31:52.976 -> {alturaConst:2271,temperaturaReferencia:25.20,humedadAmbiente:52.49,temperaturaAmbiente:24.50,co2ppmAmbiente:844,humedadSustrato:319.00,ventilador:0}
21:31:52.976 ->
```

# Ciclo de vida de modelos



## Model

The output of an ML algorithm trained on a data set; used for data prediction



## Training

The act of creating a model from past data



## Testing


Measuring the performance of a model on test data



## Deployment

Integrating a model into a production pipeline

# ¿Cuándo **NO** usar AI (ML)?




## Can be solved with traditional algorithms

If the problem is not overly complex, an ML solution might be overcomplicated.



## Does not require adapting to new data

If data and conditions are not changing, a more traditional approach could be more appropriate.



## Requires 100% accuracy

ML predictions often provide less than 100% accuracy.



## Requires full interpretability

If being able to explain what is going to happen if you change the parameters or input is a priority, ML might not be the best solution.

# ¿Cuándo **SÍ** usar AI (ML)?



## Requires complex logic

Since developing personalized recommendations requires complex logic, ML is an appropriate tool to consider.




## Requires scalability

Serving millions of requests for personalized recommendations every second is a challenge.



## Requires personalization

Delivering personalized recommendations at scale and being responsive at the same time is difficult to achieve with classical programming techniques.



## Requires responsiveness

The ability to deliver personalized recommendations within a few seconds even while handling millions of requests per second is expected.

125 min. Taller

# Dinámica de trabajo

Todo mundo puede compartir su conocimiento

Los ejercicios los estaremos haciendo sobre:

- Línea de comandos
- Jupyter
- Google Colab

[https://github.com/FunkyM0nk3y/FSL\\_Vallarta-2024](https://github.com/FunkyM0nk3y/FSL_Vallarta-2024)





# Preguntas

## 10 min.





# Aprendizajes


10 min.





# Indicadores para los modelos

Simple model




Accuracy



Explainability

Complex model



Accuracy



Explainability

# ¿Cómo llevar una estrategia de **AI** exitosa?



## Robust AI strategy

- Start with important projects as proofs of concept
- Gain momentum using these projects
- Explain the why behind the shift towards AI



## Data strategy

- Explore and document where the data resides
- Document if the data can be used for an AI project
- Prepare a timeline for building a data pipeline if there isn't one



## Culture of learning and collaboration

- Allow teams to explore and experiment with the data
- Team up with external resources
- Leverage managed services



# Referencias



# Libros

## Building Data Science Teams

by DJ Patil

Copyright © 2011 O'Reilly Media

## Machine Learning Is Changing the Rules

by Peter Morgan

Copyright © 2018 O'Reilly Media

## Big Data Glossary

by Pete Warden

Copyright © 2011 Pete Warden

## The Evolution of Data Products

by Mike Loukides

Copyright © 2011 O'Reilly Media

## Data Driven

by DJ Patil, Hilary Mason

Copyright © 2015 O'Reilly Media

## The Art of Data Science

By Roger D. Peng and Elizabeth Matsui

# Otros recursos

## Competencias en Kaggle

<https://www.kaggle.com/competitions>

## ¿A quién seguir en twitter?

@drewconway (Drew Conway)

@rdpeng (Roger D Peng)

@AndrewYNg (Andrew Ng)

@ylecun (Yan LeCun)

@martinkl (Martin Kleppmann)

@mikeloukides (Mike Loukides)

@dpatil (DJ Patil)



**¡Muchas gracias!**  
**funkymonster@linux.com**

